
BAB 3

REPRESENTASI DATA

3.1 TUJUAN PERCOBAAN

Setelah mengikuti praktikum ini, mahasiswa diharapkan mampu:

1. Setelah mengikuti modul bagian ini diharapkan mahasiswa dapat mengetahui secara sekilas bagaimana menggunakan Python untuk membangun suatu proyek pembelajaran mesin.
2. Detil masing-masing bagian akan disampaikan pada sesi praktikum berikutnya.

3.2 ALAT-ALAT YANG DIGUNAKAN

Pada percobaan ini, akan digunakan berbagai alat dan bahan yang mendukung kegiatan praktikum. Alat-alat tersebut meliputi:

- Daftar alat utama: OS Windows/Linux/macOS, Anaconda, Google Colab
- Pustaka: pandas, numpy, matplotlib, scipy, scikit-learn

3.3 DASAR TEORI

3.3.1 NUMPY

NumPy (Numerical Python) adalah library dasar untuk komputasi numerik di Python. Library ini menyediakan objek array multidimensi (*ndarray*) yang efisien serta berbagai fungsi matematika dan aljabar linier.

Kegunaan:

- Operasi matematika pada array dan matriks.
- Fungsi statistik dan transformasi data.
- Basis untuk banyak library lain dalam ekosistem data science.

3.3.2 PANDAS

Pandas adalah library yang dirancang untuk memudahkan manipulasi dan analisis data, terutama data dalam format tabel. Dengan struktur data seperti *DataFrame* dan *Series*, Pandas memungkinkan pengguna untuk:

Kegunaan:

- Melakukan filtering, agregasi, dan transformasi data.
- Menangani data yang hilang dan melakukan pembersihan data.
- Menggabungkan dan mengelompokkan data dari berbagai sumber.

3.3.3 MATPLOTLIB

Matplotlib adalah library visualisasi data yang sangat fleksibel untuk membuat berbagai jenis grafik dan plot. Dengan Matplotlib, pengguna dapat:

Kegunaan:

- Membuat plot garis, bar chart, scatter plot, histogram, dan banyak jenis grafik lainnya.
- Menyesuaikan tampilan grafik dengan berbagai opsi styling dan layout.
- Menampilkan data secara visual sehingga memudahkan interpretasi dan presentasi.

3.3.4 SCIPY

SciPy adalah library yang dibangun di atas NumPy dan menyediakan fungsi-fungsi untuk komputasi ilmiah yang lebih kompleks.

Kegunaan:

- Optimasi, integrasi numerik, dan pemecahan persamaan diferensial.
- Interpolasi, transformasi sinyal, dan analisis statistik.
- Cocok untuk aplikasi teknik dan riset ilmiah yang membutuhkan perhitungan matematis tingkat lanjut.

3.3.5 SCIKIT-LEARN

Scikit-learn adalah library machine learning yang menyediakan berbagai algoritma dan alat bantu untuk pemodelan data.

Kegunaan:

- Algoritma klasifikasi, regresi, *clustering*, dan reduksi dimensi.
- Validasi model, pemilihan fitur, dan evaluasi performa model.
- Antarmuka yang konsisten dan mudah digunakan, membuatnya populer di kalangan praktisi machine learning.

3.4 PROSEDUR PERCOBAAN

3.4.1 INSTALASI LIBRARY

Terdapat lima pustaka utama yang sering digunakan dalam pembelajaran mesin yang perlu diinstalasi terlebih dahulu sebelum Anda melakukan praktikum. *Library* tersebut adalah:

1. Numpy
2. Pandas
3. Matplotlib
4. Scipy
5. Scikit-learn

Namun demikian hal ini bisa dilewati jika anda tidak perlu menginstal di komputer anda, karena hal ini bisa dilakukan secara *online* menggunakan Google Colab. Colab singkatan dari Colaboratory yang memungkinkan Anda untuk menulis dan mengeksekusi Python melalui browser secara remote.

Dengan demikian Anda tidak perlu menginstall secara local dan mengkonfigurasi tools tersebut di atas. Jalankan kode berikut pada *cell* di Google Colab untuk mengecek apakah library tersebut telah terinstalasi.

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import scipy
import sklearn
import csv

print(f'numpy: {np.__version__}') # numpy
print(f'pandas: {pd.__version__}') # pandas
print(f'matplotlib: {plt.__version__}') # matplotlib
print(f'scipy: {scipy.__version__}') # scipy
print(f'sklearn: {sklearn.__version__}') # scikit-learn
```

Jika Anda melakukan dengan benar, maka contoh *output* yang dihasilkan adalah:

```
numpy: 1.24.0  
pandas: 1.5.3  
matplotlib: 3.6.3  
scipy: 1.9.3  
sklearn: 1.1.3
```

Versi pustaka ini bisa berbeda tergantung pada pembaruan di lingkungan Google Colab.

3.4.2 MEMUAT DATASET

Setelah tools siap dipakai, langkah selanjutnya memanggil *dataset* yang akan diolah. Terdapat beberapa cara untuk memuat *dataset*: memuat dari file lokal atau mengunduh dari Internet.

3.4.2.1 Memuat Dataset Lokal

Buatlah sebuah file CSV dengan nama kontak.csv. Anda dapat menggunakan aplikasi Notepad atau teks editor lainnya, dan simpan berkas dengan nama kontak.csv. Isi berkas kontak.csv adalah:

```
NO,NAMA,TELEPON  
1,Achmad Ali,081234  
2,Budi Utomo,08712333  
3,Toni Saja,08733311  
4,Dewi Utami,0851231
```

Anda dapat mengunggah (upload) berkas **kontak.csv** ke Google Colab dengan menggunakan kode berikut.

```
from google.colab import files  
  
kontak = files.upload()  
  
for fn in kontak.keys():  
    print(f'Nama file "{fn}" dengan panjang {len(kontak[fn])} bytes')
```

Setelah dijakankan, akan muncul tombol untuk mengunggah file sebagai berikut.

... Choose Files No file chosen Cancel upload

Klik **Choose Files** dan pilih *file* yang akan diunggah. Contoh keluaran dari proses unggah *file* adalah:

```
→ Choose Files kontak.csv  
• kontak.csv(text/csv) - 105 bytes, last modified: 2/23/2025 - 100% done  
Saving kontak.csv to kontak.csv  
Nama file "kontak.csv" dengan panjang 105 bytes
```

Berkas **kontak.csv** telah sukses terunggah.

3.4.2.2 Memuat *Dataset* dari Internet

Apabila *dataset* telah tersedia di Internet, maka Anda dapat langsung mengunduh (download) langsung ke Google Colab. Anda dapat memanfaatkan aplikasi **wget** yang tersedia di Google Colab untuk mengunduh data. Pada praktikum ini, Anda akan mengunduh *dataset iris* yang tersedia di <https://dataset-ppm.s3.amazonaws.com/iris.csv>. Jalankan code di bawah ini untuk mengunduh berkas **iris.csv**. Jangan lupa menuliskan tanda seru (!) di depan perintah wget.

```
! wget https://dataset-kal.s3.us-east-1.amazonaws.com/iris_missing.csv
```

Cek menggunakan perintah **ls** untuk mendapatkan file yang tersedia di Google Colab.

```
!ls
```

Jika Anda melakukan perintah yang ada dengan urutan yang benar, maka hasilnya adalah:

```
↔ iris_missing.csv kontak.csv sample_data
```

Artinya, di Google Colab sudah terdapat berkas **iris.csv** dan **kontak.csv**.

3.4.2.3 Membaca format CSV

File CSV dapat diuraikan (parsing) ke dalam bentuk *list* atau *dictionary*. Fungsi di bawah ini digunakan untuk mengubah CSV menjadi *list*.

```
import csv

def csv_list(filename):
    data = []

    with open(filename, mode='r') as csv_file:
        csv_reader = csv.reader(csv_file, delimiter=",")

        for row in csv_reader:
            data.append(row)

    data.pop(0) # Menghapus baris header
    return data
```

Cek apakah fungsi `csv_list` dapat berjalan dengan baik.

```
list_kontak = csv_list('kontak.csv')

print(list_kontak)
```


Dictionary adalah struktur data yang tersusun dari *key* dan *value*. Untuk memarsing CSV menjadi *dictionary*, gunakan fungsi `DictReader()`.

```
import csv

def csv_dict(filename):
    data = []

    with open(filename, mode='r') as csv_file:
        csv_reader = csv.DictReader(csv_file)

        for row in csv_reader:
            data.append(row)

    return data
```

Cek apakah fungsi `csv_dict` dapat berjalan dengan baik.

```
# Menyimpan konten CSV ke dalam file
with open(csv_filename, mode='w') as file:
    file.write(csv_content)

# Uji fungsi csv_dict
csv_data = csv_dict(csv_filename)

# Menampilkan hasil pengujian
print("Hasil dari csv_dict:")
for row in csv_data:
    print(row)
```

3.4.2.4 Membaca CSV menggunakan Pandas

Pandas merupakan library Python yang digunakan untuk membuat dan mengolah *DataFrame*. *DataFrame* merupakan struktur data dua dimensi yang menyerupai tabel pada Microsoft Excel. *DataFrame* memiliki fitur yang memudahkan pengaksesan dan pemrosesan data.

Pandas memiliki fitur untuk mengambil data dari CSV dengan mudah. Jalankan code di bawah ini untuk membentuk *DataFrame* dari berkas **iris.csv**.

```
iris_df = pd.read_csv('/content/iris_missing.csv')
```

Anda dapat melihat sebagian isi *DataFrame* menggunakan properti **head** dari *DataFrame* yang bersangkutan.

```
iris_df.head()
```

Properti **head** akan menampilkan 5 data teratas dari *DataFrame*.

	sepal_length	sepal_width	petal_length	petal_width	Species
0	5.1	3.5	1.4	0.2	Iris-setosa
1	4.9	3.0	1.4	0.2	Iris-setosa
2	0.0	3.2	1.3	0.2	Iris-setosa
3	4.6	3.1	1.5	0.2	Iris-setosa
4	5.0	3.6	1.4	0.2	Iris-setosa

3.4.3 MERINGKAS KUMPULAN DATA

Terdapat beberapa informasi yang dapat diketahui dengan mudah dari struktur *DataFrame* pada Pandas, yaitu:

Dimensi *dataset*

Melihat isi *dataset*

Ringkasan statistik dari *dataset*

Rincian data dengan variabel kelas

Tabel berikut berisi fungsi/properti beserta kegunaannya.

Fungsi/properti	Deskripsi
shape	Menampilkan dimensi <i>DataFrame</i> (banyak baris dan kolom)
head(n)	Menampilkan n baris pertama dari data
describe()	Menampilkan distribusi data
groupby(column_name)	Melakukan grouping berdasarkan kolom tertentu

Kode berikut menampilkan ringkasan dari *DataFrame* **iris_df**.

```
print(iris_df.head(6)) # menampilkan 6 data pertama
print(iris_df.shape) # menampilkan dimensi dataframe
print(iris_df.describe()) # menampilkan distribusi data
print(iris_df.groupby('species').size()) # menampilkan banyak data per kelas
```

3.4.4 VISUALISASI KUMPULAN DATA

Data dapat divisualisasi menggunakan grafik dengan cara di-ploting. Ada dua cara *plotting*:

- Plot univariat untuk lebih memahami setiap atribut
- Plot multivariasi untuk lebih memahami hubungan antar atribut

Plot univariat merupakan plot dari masing-masing variabel. Mengingat variabel input berupa numerik, kita dapat membuat *box plot* dan *whisker*.


Kode berikut menampilkan *box plot*.

```
from matplotlib import pyplot

iris_df.plot(kind='box', subplots=True, layout=(2,2), sharex=False, sharey=False)

pyplot.show()
```

Hasilnya berupa *box plot*.




Kita juga dapat membuat histogram dari setiap variabel input untuk mendapatkan gambaran tentang distribusinya.

```
iris_df.hist()

pyplot.show()
```

Hasilnya berupa plot histogram.




Plot multivariasi dapat memanfaatkan scatter plot untuk melihat interaksi antar variable.

```
from pandas.plotting import scatter_matrix
import matplotlib.pyplot as plt

scatter_matrix(iris_df)
plt.show()
```

Hasilnya merupakan scatter plot yang menggambarkan sebaran data antar dua variable.




3.5 TUGAS

1. Unduh Glass dataset dari <https://archive.ics.uci.edu/dataset/42/glass+identification>
2. Masukkan data Glass ke *DataFrame* menggunakan Pandas.
3. Tampilkan 10 data pertama
4. Hitung rata-rata nilai per variabel untuk setiap data
5. Hitung rata-rata nilai per variabel untuk setiap data dikelompokkan berdasarkan Type
6. Buatlah plot bertipe 'line' untuk masing-masing variabelnya. Referensi: [Pandas Plot](#)

Petunjuk pengerjaan soal:

1. Buka tautan berikut, pastikan Anda *login* menggunakan **akun Student UB**.
<https://s.ub.ac.id/nbkal03>
2. Klik tombol **Copy to Drive**



3. Beri nama file **Praktikum 3 - Nama - NIM.ipynb**
4. Isilah *cell* yang kosong.
5. Unduh file ***.ipynb** dengan cara klik **File > Download .ipynb**
6. Kumpulkan file ***.ipynb** ke asisten

3.6 KESIMPULAN

Pemahaman tentang representasi data merupakan fondasi utama dalam analisis data dan pembelajaran mesin. Proses pengolahan data dimulai dari tahapan akuisisi data, pemrosesan awal, eksplorasi, hingga visualisasi untuk mendapatkan wawasan yang bermakna. Penggunaan library Python seperti Pandas, NumPy, Matplotlib, Scipy, dan Scikit-learn mempermudah berbagai proses pengolahan data, mulai dari manipulasi *dataset*, analisis statistik, hingga pembuatan visualisasi yang informatif.

Dalam percobaan ini, mahasiswa diperkenalkan pada cara mengimpor dan menampilkan data, menghitung statistik dasar seperti rata-rata dan distribusi data, serta membuat visualisasi sederhana seperti boxplot, histogram, dan scatter plot matrix. Pemahaman tentang teknik ini penting untuk memastikan kualitas data yang akan digunakan dalam proses analisis lebih lanjut atau pelatihan model machine learning.

Melalui latihan yang diberikan, mahasiswa diharapkan dapat mengembangkan keterampilan dalam mengolah *dataset* nyata, memahami karakteristik data berdasarkan variabel, serta menginterpretasikan hasil visualisasi untuk mendukung pengambilan keputusan berbasis data. Dengan pendekatan ini, kemampuan analisis data mahasiswa akan semakin terasah, mempersiapkan mereka menghadapi tantangan dalam bidang data science dan machine learning di masa depan.