
BAB 11 EVALUASI CLUSTERING

11.1 TUJUAN PERCOBAAN

Tujuan dari percobaan ini adalah untuk memberikan pemahaman kepada mahasiswa mengenai Evaluasi Clustering. Melalui praktikum ini, mahasiswa diharapkan mampu:

1. Memahami konsep evaluasi clustering baik untuk clustering dengan label (supervised) maupun tanpa label (unsupervised).
2. Menerapkan berbagai metrik evaluasi clustering seperti Silhouette Score, Davies-Bouldin Index, dan Calinski-Harabasz Index menggunakan Python.
3. Menganalisis hasil evaluasi untuk menentukan kualitas model clustering.

11.2 ALAT-ALAT YANG DIGUNAKAN

- Komputer/laptop dengan Python terinstal.
- Google Colab atau Jupyter Notebook.
- Library Python: `scikit-learn`, `matplotlib`, `seaborn`, `numpy`, `pandas`.
- Dataset: Iris Dataset atau dataset clustering lainnya.

11.3 DASAR TEORI

Evaluasi clustering bertujuan untuk menilai seberapa baik hasil clustering. Evaluasi dibagi menjadi dua jenis utama:

1. **Internal Evaluation:** Menggunakan informasi dari data itu sendiri (tanpa label) untuk menilai kualitas clustering.
 - *Silhouette Score*: Mengukur seberapa mirip objek dengan cluster-nya sendiri dibandingkan dengan cluster lain.
 - *Davies-Bouldin Index*: Rasio antara jarak intra-cluster dan inter-cluster, semakin kecil nilainya semakin baik.
 - *Calinski-Harabasz Index*: Rasio antara varians antar-cluster dan varians dalam-cluster, semakin besar semakin baik.
2. **External Evaluation:** Jika ground truth tersedia, menggunakan label sebenarnya.
 - *Adjusted Rand Index*, *Mutual Information Score*, dll.

Evaluasi yang tepat membantu dalam memilih jumlah cluster yang optimal dan algoritma clustering terbaik.

11.4 PROSEDUR PERCOBAAN

1. Persiapan:

Install library yang diperlukan jika belum ada:

```
!pip install scikit-learn matplotlib seaborn
```

2. Import Library:

```
import numpy as np
import pandas as pd
from sklearn.cluster import KMeans
from sklearn.datasets import load_iris
from sklearn.metrics import silhouette_score, davies_bouldin_score,
calinski_harabasz_score, adjusted_rand_score
import matplotlib.pyplot as plt
import seaborn as sns
```

3. Load Dataset:

```
data = load_iris()
X = data.data
Y = data.target
```

4. Clustering:

```
kmeans = KMeans(n_clusters=3, random_state=42)
labels = kmeans.fit_predict(X)
```

5. Evaluasi:

```
sil_score = silhouette_score(X, labels)
db_index = davies_bouldin_score(X, labels)
ch_score = calinski_harabasz_score(X, labels)
rand_index = adjusted_rand_score(Y, labels)

print(f"Silhouette Score: {sil_score}")
print(f"Davies-Bouldin Index: {db_index}")
print(f"Calinski-Harabasz Index: {ch_score}")
print(f"Rand score: {rand_index}")
def purity_score(y_true, y_pred):
    # Compute contingency matrix
    contingency_matrix = np.zeros((np.max(y_pred)+1, np.max(y_true)+1))
    for i in range(len(y_true)):
        contingency_matrix[y_pred[i]][y_true[i]] += 1
    return np.sum(np.amax(contingency_matrix, axis=1)) /
```

```
np.sum(contingency_matrix)

purity = purity_score(Y, labels)
print(f"Purity: {purity}")
```

6. Visualisasi Cluster:

```
sns.scatterplot(x=X[:, 0], y=X[:, 1], hue=labels, palette='viridis')
plt.title("Cluster Visualization")
plt.show()
```

11.5 TUGAS

1. Uji evaluasi clustering untuk jumlah cluster 2 hingga 6. Catat dan bandingkan hasilnya.
2. Coba dataset Wine dari `sklearn.datasets`. Lakukan evaluasi clustering dan bandingkan hasilnya.
3. Jelaskan kapan Silhouette Score lebih baik digunakan daripada Davies-Bouldin Index.

11.6 KESIMPULAN

Setelah melakukan praktikum ini mahasiswa diwajibkan untuk membuat kesimpulan.

Kesimpulan dari percobaan ini merupakan bagian penting untuk merangkum temuan utama dan relevansinya dengan tujuan percobaan. Mahasiswa harus mampu menyimpulkan:

- Apakah tujuan percobaan telah tercapai.
- Hubungan antara hasil percobaan dan dasar teori.
- Faktor-faktor yang memengaruhi hasil percobaan, termasuk kemungkinan kesalahan yang terjadi.

Kesimpulan harus disusun secara singkat, jelas, dan berdasarkan data yang diperoleh